

BÁO CÁO KỸ THUẬT - BÀI TẬP 1

Hiểu dữ liệu, chọn dữ liệu và tiền xử lý

1. Mục tiêu và ma trận dữ liệu - kỹ thuật

Bài tập khảo sát ba bộ dữ liệu công khai có cấu trúc khác nhau để phủ đủ ba kỹ thuật khai phá: phân lớp, luật kết hợp và gom cụm. Mỗi bộ dữ liệu được dùng cho đúng hai kỹ thuật. Các nguồn đều đáp ứng điều kiện quy mô tối thiểu ở mức dữ liệu nguồn hoặc bản tiền xử lý chung: tối thiểu 10.000 bản ghi và 30 thuộc tính.

Bộ dữ liệu	Quy mô dùng để đánh giá	Phân lớp	Luật kết hợp	Gom cụm
Olist Brazilian E-Commerce	117.891 x 35 sau tích hợp	X	-	X
Inside Airbnb - NYC	30.259 x 81 sau tiền xử lý	-	X	X
US Accidents	80.000 x 48 sau lấy mẫu	X	X	-

Quy trình chung

Notebook [bai-1/khao-sat.ipynb](#) đọc dữ liệu nguồn, tạo từ điển dữ liệu, kiểm tra thiếu/trùng/nhiều và ngoại lai, thực hiện biến đổi đặc trưng, sau đó xuất sáu tập dữ liệu chuyên biệt. Python được dùng với pandas, numpy, scikit-learn, mlxtend, matplotlib và seaborn. Các đường dẫn đều tương đối để notebook có thể chạy lại từ thư mục Bài 1.

Nguồn dữ liệu

Olist	Kaggle: Brazilian E-Commerce Public Dataset; 9 bảng quan hệ, liên kết qua order/customer/product/seller.
Airbnb	Inside Airbnb: Detailed Listings, New York City; một listing là một đơn vị quan sát, tiện nghi là tập đa trị.
US Accidents	Kaggle: US Accidents 2016-2023; notebook đọc theo chunk, chỉ giữ CA và TX rồi lấy mẫu 80.000 dòng tái lập.

Lưu ý: Olist ở dạng nhiều bảng nên từng file raw có ít thuộc tính; yêu cầu quy mô được kiểm chứng sau khi tích hợp thành bảng phân tích.

2. Bộ 1 - Olist Brazilian E-Commerce

Dữ liệu Olist mô tả vòng đời đơn hàng thương mại điện tử: đặt hàng, phê duyệt, vận chuyển, giao hàng, sản phẩm, người bán, khách hàng và thanh toán. Hai kỹ thuật được chọn là phân lớp giao trễ và gom cụm khách hàng. Luật kết hợp không được chọn vì khảo sát giỏ hàng cho thấy đa số đơn hàng chỉ có một sản phẩm/ngành hàng, nên ít khả năng sinh luật đáng tin cậy.

Tiền xử lý và đặc trưng

Nội dung	Quyết định kỹ thuật
Tích hợp	Join bảng orders, customers, order_items, products, sellers, payments, reviews và bảng dịch ngành hàng; giữ mức độ chi tiết phù hợp cho từng kỹ thuật.
Thiếu và nhiều	Không điền ngày giao thực tế bị thiếu vì thường phản ánh đơn chưa hoàn tất; xử lý các trường danh mục bằng unknown khi cần; kiểm tra ràng buộc thời gian.
Ngoại lai	Khảo sát IQR cho price/freight và các biến số; phân biệt giá trị cực trị hợp lệ với lỗi dữ liệu trước khi loại/biến đổi.
Phân lớp	Tạo delivery_delay_days và target_is_late từ ngày giao thực tế so với ngày giao dự kiến; thêm month, day-of-week, hour, số item, số sản phẩm/seller khác nhau, tổng giá và cước.
Gom cụm	Tạo RFM theo customer_unique_id: recency_days, frequency, monetary; cần chuẩn hóa ở Bài 4 vì các thang đo khác nhau.

Kết quả bàn giao Olist

File bàn giao	Kích thước	Ý nghĩa
olist_preprocessed.csv	117.891 x 35	Bảng Olist đã làm sạch chung
olist_classification.csv	96.476 x 11	Target is_late; giao trễ 6,77%
olist_clustering.csv	96.096 x 4	Khách hàng + ba đặc trưng RFM

RFM có median: Recency 268 ngày, Frequency 1 đơn và Monetary 108. Đây là cơ sở mô tả phân khúc ở Bài 4.

3. Bộ 2 - Inside Airbnb, New York City

Bộ Detailed Listings NYC ban đầu có 54.281 listing và 90 thuộc tính. Các biến gồm thông tin host, loại phòng, sức chứa, giá, đánh giá, availability và danh sách amenities. Luật kết hợp được chọn vì mỗi listing tự nhiên là một giao dịch gồm nhiều tiện nghi; gom cụm được chọn để phân nhóm listing theo giá, sức chứa, chất lượng đánh giá và mức độ hoạt động.

Nội dung	Quyết định kỹ thuật
Chuẩn hóa	Chuyển price sang số; xử lý các biến tỷ lệ và ngày tháng; loại cột trống hoàn toàn hoặc định danh/URL không phù hợp làm đầu vào mô hình.
Thiếu	Với biến số dùng cho clustering, điền median theo room_type rồi median toàn cục; các listing chưa có review được nhận diện từ number_of_reviews.
Tiện nghi	Parse amenities thành list; TransactionEncoder tạo ma trận nhị phân; lọc item quá hiếm để giảm số chiều và luật nhiễu.
Ngoại lai	Khảo sát giá, minimum_nights, sức chứa và phòng; các giá trị cực trị được cân nhắc theo ý nghĩa nghiệp vụ thay vì loại máy móc.

Kết quả bàn giao Airbnb

File bàn giao	Kích thước	Ý nghĩa
airbnb_preprocessed.csv	30.259 x 81	Bản làm sạch chung
airbnb_association.csv	30.218 x 182	Ma trận item tiện nghi cho Apriori/FP-Growth
airbnb_clustering.csv	30.259 x 16	Đặc trưng số cho clustering

Tập luật kết hợp có trung bình 27,80 item/giao dịch, median 28 và 99,93% listing có ít nhất hai tiện nghi; do đó phù hợp để khai phá luật.

4. Bộ 3 - US Accidents và tổng kết

Dữ liệu US Accidents gốc có 7.728.394 bản ghi và 46 thuộc tính. Để bảo đảm chạy được trong phạm vi thực hành, notebook đọc theo chunk, lọc CA/TX và lấy mẫu ngẫu nhiên tái lập 80.000 dòng. Phân lớp dự đoán Severity (1-4); luật kết hợp tìm đồng xuất hiện giữa hạ tầng, khung giờ, ngày/đêm, thời tiết, nhiệt độ và nhóm mức độ nghiêm trọng.

Nội dung	Quyết định kỹ thuật
Thiếu	Loại End_Lat/End_Lng thiếu nhiều; giữ các biến cần thiết và tạo cờ Precipitation_missing; impute median theo State/Month cho tập classification bàn giao.
Biến đổi	Tạo Hour_of_Day, Day_of_Week, Is_Weekend, Infra_Feature_Count và Temperature_Bin; rời rạc hóa thời tiết/ánh sáng cho luật kết hợp.
Phân lớp	Giữ 22 đặc trưng thời tiết, thời gian và hạ tầng cùng Severity; cần dùng F1-macro/class_weight ở Bài 2 vì lớp 2 áp đảo.
Luật kết hợp	Gộp cờ hạ tầng và item thời gian/thời tiết/mức độ; lọc support < 0,1% để hạn chế item quá hiếm.

Kết quả bàn giao US Accidents

File bàn giao	Kích thước	Kiểm tra quan trọng
accidents_preprocessed.csv	80.000 x 48	Bản làm sạch chung
us_accidents_classification.csv	80.000 x 23	0 missing; Severity 2 = 81,67%
us_accidents_association_transactions.csv	80.000 x 32	0 missing; 6,37 item/giao dịch; >=2 item = 100%

Tổng kết

Bài 1 đã tạo sáu tập dữ liệu đúng với ma trận kỹ thuật và kiểm tra điều kiện đầu vào: tất cả tập chuyên biệt đều không có giá trị thiếu. Các tập phân lớp giữ lại biến dự báo phục vụ mô hình; các tập luật kết hợp là ma trận bool sẵn sàng cho mlxtend; các tập clustering chỉ giữ đặc trưng số có ý nghĩa. Khi làm Bài 2-4, cần tiếp tục fit scaling/imputation trên train để tránh rò rỉ dữ liệu, đánh giá bằng độ đo phù hợp và giải thích lựa chọn siêu tham số.

Mã nguồn: bai-1/khao-sat.ipynb | Dữ liệu đầu ra: data/processed/{olist, airbnb, us_accidents}/