


BÁO CÁO KỸ THUẬT - BÀI TẬP 2

Phân lớp mức độ nghiêm trọng tai nạn giao thông US Accidents

1. Bài toán và dữ liệu

Mục tiêu là dự đoán Severity, mức độ nghiêm trọng của mỗi vụ tai nạn gồm bốn lớp từ 1 đến 4. Bộ dữ liệu gốc US Accidents có 7.728.394 bản ghi và 46 thuộc tính; sau tiền xử lý, nhóm lấy mẫu tái lập 80.000 bản ghi x 48 thuộc tính. Tập phân lớp giữ 22 đặc trưng dự báo và một biến mục tiêu, gồm điều kiện thời tiết, thời gian và các cờ hạ tầng giao thông.

Tập phân lớp không có giá trị thiếu; các cột boolean đã ở dạng nhị phân, các cột còn lại là số. Vì vậy không cần mã hóa hạng mục. Lưu ý, ngưỡng quy mô ≥ 10.000 bản ghi x 30 thuộc tính được đáp ứng bởi bộ dữ liệu gốc và bản tiền xử lý chung; file phân lớp là tập con đặc trưng phục vụ mô hình.



Hình 1. Severity 2 chiếm 81,67%; Severity 1 và 4 là các lớp rất hiếm.

Lớp	Số lượng	Tỷ lệ
1	520	0,65%
2	65.334	81,67%
3	13.439	16,80%
4	707	0,88%

2. Thiết kế thí nghiệm

Dữ liệu được tách theo tỉ lệ 64% train - 16% validation - 20% test bằng `stratify=y` và `random\_state=42`; do đó tỷ lệ bốn lớp được giữ trong mọi tập. Test set được giữ độc lập, chỉ dùng một lần cho đánh giá cuối. `StandardScaler` nằm trong Pipeline của Logistic Regression và chỉ được fit trên train; Decision Tree không cần co giãn đặc trưng.

Do mất cân bằng mạnh, cả hai mô hình đều dùng `class\_weight='balanced'`. Điều này tăng phạt cho lỗi ở Severity 1 và 4, đổi lại accuracy tổng có thể giảm. F1-macro được chọn là thước đo chính vì tính điểm ngang nhau cho mọi lớp; accuracy, balanced accuracy, báo cáo precision/recall/F1 và ma trận nhầm lẫn được trình bày kèm theo.

Mô hình	Giả định / đặc điểm kỹ thuật	Thiết lập
Dummy	Luôn dự đoán lớp phổ biến nhất; là mốc để phát hiện accuracy đánh lừa.	most_frequent
Logistic Regression	Giả định log-odds có quan hệ tuyến tính với đặc trưng; quan sát độc lập; cần scale biến liên tục.	balanced, lbfgs, max_iter=2000
Decision Tree	Không giả định tuyến tính hay phân phối chuẩn; chia theo ngưỡng từng đặc trưng, nhưng dễ overfit nếu cây quá sâu.	balanced, min_samples_leaf=20


Chọn siêu tham số

Với Decision Tree, nhóm thử `max\_depth` = 4, 6, 8, 10, 12 và giữ `min\_samples\_leaf=20` để hạn chế lá chỉ chứa vài quan sát hiếm. F1-macro trên validation lần lượt là 0,1591; 0,2016; 0,2623; 0,2663; 0,2760. Vì độ sâu 12 cao nhất nên được chọn. Logistic Regression được dùng như baseline tuyến tính cân bằng với cấu hình hội tụ ổn định; F1-macro validation là 0,2069.

max_depth	4	6	8	10	12
F1-macro validation	0,1591	0,2016	0,2623	0,2663	0,2760

3. Kết quả và nhận xét kỹ thuật

Mô hình	Accuracy	Balanced Acc.	F1-macro	ROC-AUC OvR macro
Dummy lớp đa số	0,8167	0,2500	0,2248	-
Logistic Regression	0,3222	0,4629	0,2127	0,7147
Decision Tree depth=12	0,4843	0,5297	0,2881	0,7075



Hình 2. F1-macro cho thấy Decision Tree tốt nhất dù accuracy thấp hơn Dummy.

Đánh giá theo lớp của Decision Tree

Severity	Precision	Recall	F1-score	Support
1	0,0283	0,5385	0,0537	104
2	0,9383	0,4537	0,6116	13.067
3	0,3341	0,6302	0,4367	2.688
4	0,0266	0,4965	0,0505	141

Kết luận. Dummy đạt accuracy 0,8167 chỉ vì luôn đoán Severity 2, nhưng bỏ sót hoàn toàn ba lớp còn lại; vì vậy không phù hợp. Decision Tree đạt F1-macro và balanced accuracy cao nhất, cho thấy có khả năng nhận diện tốt hơn các lớp thiểu số. Tuy nhiên, precision của Severity 1 và 4 vẫn rất thấp (lần lượt 0,0283 và 0,0266), nghĩa là mô hình tạo nhiều dự đoán dương giả cho các lớp hiếm. Logistic Regression có ROC-AUC OvR macro cao hơn nhẹ, nhưng điểm phân lớp mặc định chưa cân bằng được F1-macro. Về giới hạn, dữ liệu được impute ở Bài 1 trước khi tách train/test nên có rò rỉ nhẹ về lý thuyết; quy trình mô hình hóa hiện tại đã tránh rò rỉ từ scaling và tuning.

Mã nguồn thực nghiệm: [bai2-phan-lop/phan-lop.ipynb](#). Dữ liệu đầu vào: [data/processed/us_accidents/us_accidents_classification.csv](#).