


B O C O K T H U T - B I T P 2

Ph n l p m c nghi m tr ng tai n n giao th ng US Accidents

1. B i t o n v d l i u

M c ti u l d o n Severity, m c nghi m tr ng c a m i v tai n ng m b n l p t 1 n 4. B d li u g c US Accidents c 7.728.394 b nghi v 46 thu c t nh; sau ti n x l , nh m l y m u t i l p 80.000 b nghi x 48 thu c t nh. T p ph n l p gi 22 c tr ng d b o v m t b i n m c t i u, g m i u k i n t h i t i t, t h i gian v c c c h t, ng giao th ng.

T p ph n l p kh ng c gi tr i thi u; c c c t boolean , ... d ng nh i ph n, c c c t c t n l i l s . V i v y kh ng c, n m, h a h ng m c. L u , ng e ng quy m ≥ 10.000 b nghi x 30 thu c t nh c p ng b i b d li u g c v b n t i n x l chung; file ph n l p l t p con c tr ng ph c v m h nh.



Hình 1. Severity 2 chi m 81,67%; Severity 1 v 4 l c c l p r t h i m.

L p	S i e ng	T S l
1	520	0,65%
2	65.334	81,67%
3	13.439	16,80%
4	707	0,88%

2. Thi t k th nghi m

D li u €%c t ch theo t l 64% train - 16% validation - 20% test b£ng `stratify=y` v `random\_state=42`; do t l b n l p €%c gi trong m i t p. Test set €%c gi c l p, ch d•ng m t l, n cho nh gi cu i. `StandardScaler` n£m trong Pipeline c a Logistic Regression v ch€ €%c fit tr n train; Decision Tree kh ng c, n co gi, n c tr£ng.

Do m t c n b£ng m nh, c hai m h nh u d•ng class_weight='balanced'. Ži u n y t•ng ph t cho l i... Severity 1 v 4, •i l i accuracy t•ng c th' gi m. F1-macro €%c ch n l th€ c o ch nh v t nh i'm ngang nhau cho m i l p; accuracy, balanced accuracy, b o c o precision/recall/F1 v ma tr n nh, m l n €%c tr nh b y k'm theo.

M hnh	Gi nh / c i'm k" thu t	Thi t l p
Dummy	Lu nd o n l p ph• bi n nh t; l m c ' ph thi n accuracy nh l a.	most_frequent
Logistic Regression	Gi nh log-odds c quan h tuy n t nh v i c tr£ng; quan s t c l p; c, n scale bi n li n t c.	balanced, lbfgs, max_iter=2000
Decision Tree	Kh ng gi nh tuy n t nh hay ph n ph i chu"n; chia theo ng€ ng t ng c tr£ng, nh£ng d• overfit n u c y qu s u.	balanced, min_samples_leaf=20


Ch n si u tham s

V i Decision Tree, nh m th `max\_depth` = 4, 6, 8, 10, 12 v gi `min\_samples\_leaf=20` ' h n ch l ch€ ch a v i quan s t hi m. F1-macro tr n validation l, n l€%t l 0,1591; 0,2016; 0,2623; 0,2663; 0,2760. V t s u 12 cao nh t n n €%c ch n. Logistic Regression €%c d•ng nh€ baseline tuy n t nh c n b£ng v i c u h nh h i t •n /nh; F1-macro validation l 0,2069.

max_depth	4	6	8	10	12
F1-macro validation	0,1591	0,2016	0,2623	0,2663	0,2760

3. Kết quả và nhận xét kết quả

Mô hình	Accuracy	Balanced Acc.	F1-macro	ROC-AUC OvR macro
Dummy baseline	0,8167	0,2500	0,2248	-
Logistic Regression	0,3222	0,4629	0,2127	0,7147
Decision Tree depth=12	0,4843	0,5297	0,2881	0,7075



Hình 2. F1-macro cho thấy Decision Tree tốt nhất về độ chính xác cân bằng so với Dummy.

Phân tích theo cấp độ của Decision Tree

Severity	Precision	Recall	F1-score	Support
1	0,0283	0,5385	0,0537	104
2	0,9383	0,4537	0,6116	13.067
3	0,3341	0,6302	0,4367	2.688
4	0,0266	0,4965	0,0505	141

Kết luận. Dummy có độ chính xác 0,8167 cho thấy mức độ phân loại Severity 2, nhưng độ chính xác cân bằng thấp; và độ chính xác phân loại. Decision Tree có F1-macro và balanced accuracy cao nhất, cho thấy các mô hình này phân biệt tốt hơn các lớp thiểu số. Tuy nhiên, precision của Severity 1 và 4 vẫn rất thấp (lần lượt 0,0283 và 0,0266), nghĩa là mô hình không phân biệt được các trường hợp cho các lớp hiếm. Logistic Regression có ROC-AUC OvR macro cao hơn nhất, nhưng điểm phân loại trung bình của nó về F1-macro. Vì vậy, điều cần làm tiếp theo là impute ... Bởi vì các khi thực hiện train/test nên cẩn trọng hơn về lý thuyết; quy trình mô hình hóa hiện tại, như như việc scaling và tuning.

M., nguồn tham khảo: bai2-phan-lop/phan-lop.ipynb. Dữ liệu, đường dẫn: data/processed/us_accidents/us_accidents_classification.csv.