

Báo cáo Bài 3 — Luật kết hợp (Association Rules)

1. Chuẩn bị dữ liệu giao dịch

Đơn vị giao dịch: mỗi dòng là một vụ tai nạn giao thông, mỗi cột là một item nhị phân (True/False). Dữ liệu đầu vào gồm 80.000 giao dịch × 32 item, kế thừa từ bước chuẩn bị dữ liệu trước đó (*us_accidents_association_transactions.csv*).

32 item được ghép từ 2 nhóm:

- (a) 9 cờ hạ tầng có sẵn dạng nhị phân: Crossing, Junction, Traffic_Signal, Railway, Station, Stop, Amenity, Give_Way, No_Exit.
- (b) 23 item được rời rạc hóa / one-hot từ thuộc tính số và hạng mục liên tục — xem bảng dưới.

Thuộc tính gốc	Cách rời rạc hóa	Item kết quả
Hour_of_Day (0–23)	4 khung giờ + Unknown nếu thiếu: Sáng (5–10h), Trưa/Chiều (11–16h), Tối (17–20h), Đêm (21–4h)	GioTrongNgay_*
Is_Weekend (bool)	Giữ nguyên, đổi nhãn	LoaiNgay_NgayThuong / CuoiTuan
Temperature_Bin	Nhóm nhiệt độ đã rời rạc hóa từ trước	NhietDo_* (gồm cả Unknown)
Weather_Condition (text)	Gộp nhóm theo từ khóa thời tiết	ThoiTiet_* (gồm cả Unknown)
Sunrise_Sunset	Giữ nguyên, đổi nhãn	AnhSang_Day / Night
Severity (1–4)	Gộp nhị phân: 1,2→Nhẹ; 3,4→Nặng	MucDo_Nhe / MucDo_Nang

Lý do bổ sung nhóm rời rạc hóa: nếu chỉ dùng cờ hạ tầng, hơn 92% giao dịch chỉ có 0–1 item, không đủ để sinh luật hai vế có ý nghĩa. Sau khi bổ sung, mỗi giao dịch có tối thiểu 5 item (trung bình 6,37), 100% giao dịch có ≥ 2 item.

Kiểm tra chất lượng dữ liệu (one-hot theo từng nhóm): các nhóm Khung giờ, Loại ngày, Nhiệt độ, Mức độ nghiêm trọng đều có đúng 1 item bật/giao dịch ở toàn bộ 80.000 dòng. Riêng nhóm Thời tiết có 61 giao dịch và nhóm Ánh sáng có 51 giao dịch không có item nào bật — cho thấy còn thiếu dữ liệu cục bộ ở hai nhóm này, cần lưu ý khi diễn giải các luật liên quan.

2. Thuật toán và ngưỡng

2.1. Giả định và cơ chế của từng thuật toán

- **Apriori:** dựa trên tính chất Apriori (downward closure) — mọi tập con của một tập phổ biến cũng phải phổ biến, nên có thể loại sớm các ứng viên chứa tập con không phổ biến. Duyệt theo từng mức: sinh ứng viên kích thước k từ tập phổ biến $k-1$, quét lại dữ liệu để đếm support. Có thể bùng nổ ứng viên khi $\min_support$ thấp.
- **FP-Growth:** không sinh ứng viên tường minh. Quét dữ liệu 2 lần để nén giao dịch vào cây FP-tree dùng chung tiền tố, sau đó khai thác đệ quy trên các cây điều kiện con.

Cả hai đều là thuật toán chính xác (không xấp xỉ): nhóm đã kiểm chứng ở `min_support = 1%`, hai thuật toán trả về đúng cùng một tập 1.504 tập phổ biến (so sánh tập hợp, không chỉ số lượng) — khác biệt duy nhất là cách tìm và tốc độ, không phải chất lượng kết quả.

2.2. So sánh tốc độ và ngưỡng

Thuật toán	min_support	Số tập phổ biến	Thời gian (giây)
Apriori	1%	1504	1,773
Apriori	3%	572	0,109
FP-Growth	1%	1504	0,379
FP-Growth	3%	572	0,328

Kết quả tốc độ không nhất quán: FP-Growth nhanh hơn ở `min_support 1%` (0,379s so với 1,773s), nhưng Apriori lại nhanh hơn ở 3% (0,109s so với 0,328s). Vì vậy nhóm không khẳng định một thuật toán luôn nhanh hơn thuật toán còn lại. Kết luận đúng với thực nghiệm là:

- FP-Growth thường có lợi thế khi số lượng frequent itemsets (hoặc ứng viên) lớn — điển hình ở ngưỡng support thấp, khi số ứng viên của Apriori tăng nhanh.
- Ở ngưỡng support cao, số tập phổ biến ít nên chi phí sinh/quét ứng viên của Apriori thấp, trong khi chi phí xây FP-tree của FP-Growth không còn mang lại lợi thế — vì vậy Apriori có thể nhanh hơn.

Ngưỡng cuối được chọn: `min_support = 1%`, `min_confidence = 20%`. Confidence được chọn thấp có chủ đích vì `MucDo_Nang` (mức tiêu khai phá chính) chỉ chiếm 17,7% nền — nếu để `confidence ≥ 50%` như một lựa chọn thông thường, phần lớn luật liên quan tới `MucDo_Nang` sẽ bị loại ngay từ bước sinh luật.

3. Lọc luật

Sinh luật ở `min_support 1%`, `min_confidence 20%` cho ra 9.577 luật. Áp dụng các bước lọc sau:

- **Lọc lift > 1,2:** loại luật tầm thường (gần như luôn đúng chỉ vì item nền có tần suất cao như `LoaiNgay_NgayThuong 83,5%`, `MucDo_Nhe 82,3%`) — còn 4.244 luật.
- **Lọc luật dư thừa:** loại luật có antecedent dài hơn nhưng confidence không cao hơn một luật “cha” đơn giản hơn cùng consequent — còn 2.323 luật. Tiêu chí cụ thể:

Một luật $(A \rightarrow C)$ được xem là dư thừa nếu tồn tại một luật khác $(B \rightarrow C)$ sao cho:

- $B \subset A$ (B là tập con thực sự của A , cùng về phải C); và
- $\text{confidence}(B \rightarrow C) \geq \text{confidence}(A \rightarrow C)$.

Nói cách khác: nếu đã có một điều kiện đơn giản hơn (B) cho confidence bằng hoặc cao hơn, thì thêm điều kiện vào để có A không giúp luật mạnh hơn — luật dài $A \rightarrow C$ bị coi là dư thừa và bị loại, chỉ giữ lại luật “cha” $B \rightarrow C$.

- **Lọc luật chứa item _Unknown:** nhóm luật có lift cao nhất toàn bộ tập (38–39) đều xoay quanh các cặp `_Unknown` (`ThoiTiet_Unknown`, `NhietDo_Unknown`) đồng xuất hiện — đây là hệ quả của việc hai thuộc tính cùng bị thiếu dữ liệu ở một số vụ tai nạn, không phải quan hệ nghiệp vụ thật. Các

luật này được giữ lại riêng để phát hiện vấn đề chất lượng dữ liệu, nhưng loại khỏi tập dùng để diễn giải — còn 2.178 luật “nghịệp vụ”.

4. Luật nổi bật

4.1. Luật liên quan MucDo_Nang (tai nạn nặng) — 29 luật

Điều kiện (A)	Support	Confidence	Lift
Junction, NhietDo_Vua	0,0111	0,2667	1,509
NhietDo_Vua, AnhSang_Day, LoaiNgay_CuoiTuan	0,0122	0,2588	1,464
NhietDo_Vua, LoaiNgay_CuoiTuan	0,0172	0,2454	1,388
AnhSang_Day, Junction	0,0149	0,2432	1,375
Junction	0,0219	0,2392	1,353

5 luật tiêu biểu trong tổng số 29 luật hướng tới MucDo_Nang (sắp theo lift giảm dần). Bảng đầy đủ 29 luật nằm trong notebook, mục 6.1.

Đọc luật hàng đầu: {Junction, NhietDo_Vua} → MucDo_Nang, support 1,1% (1,1% tổng số vụ tai nạn có đồng thời cả 3 điều kiện), confidence 26,7% (trong các vụ có Junction và nhiệt độ vừa, 26,7% là mức nặng — cao hơn tỷ lệ nền 17,68%), lift 1,509 (khả năng tai nạn nặng cao hơn khoảng 51% so với ngẫu nhiên).

Đây là luật mạnh nhất trong 29 luật của nhóm; phần lớn các luật còn lại có lift 1,2–1,4 — tương quan tồn tại nhưng không mạnh, khớp với nhận xét trước đó rằng Severity khó dự đoán chính xác chỉ từ vài đặc trưng đơn lẻ.

4.2. Đối chứng: luật liên quan MucDo_Nhe — 0 luật đạt ngưỡng

Sau khi loại Unknown, không có luật nào dẫn tới MucDo_Nhe đạt lift > 1,2. Đây là hệ quả toán học tất yếu: MucDo_Nhe đã chiếm 82,3% nền, nên để lift vượt 1,2 thì confidence của luật phải vượt $1,2 \times 0,823 \approx 98,8\%$ — gần như không điều kiện thực tế nào (ngoài các cờ Unknown đã loại) đạt được mức này. Ngược lại MucDo_Nang chỉ cần confidence > 21,2% để lift vượt 1,2, nên dư địa phát hiện luật rộng hơn nhiều. Đây là lý do kỹ thuật cốt lõi giải thích vì sao hướng khai phá $X \rightarrow \text{MucDo_Nang}$ giàu phát hiện hơn hẳn.

5. Tổng kết kỹ thuật

- **So sánh thuật toán:** Apriori và FP-Growth cho cùng kết quả (1.504 tập phổ biến giống hệt nhau tại min_support 1%, đã kiểm chứng bằng so sánh tập hợp). Tốc độ không nhất quán giữa hai ngưỡng thử nghiệm — FP-Growth có lợi thế rõ khi ngưỡng thấp, Apriori nhanh hơn khi ngưỡng cao — nên không kết luận một thuật toán luôn nhanh hơn.
- **Ngưỡng và quá trình lọc:** min_support 1%, min_confidence 20%, lọc lift > 1,2 — giảm từ 9.577 luật ban đầu xuống 4.244 (lọc lift), 2.323 (lọc dư thừa theo tiêu chí $B \subset A$ ở Mục 3), còn 2.178 luật nghịệp vụ sau khi loại Unknown.
- **Phát hiện chính:** 29 luật liên quan MucDo_Nang, mạnh nhất là Junction + NhietDo_Vua (lift 1,51); 0 luật liên quan MucDo_Nhe đạt cùng ngưỡng — chênh lệch bắt nguồn từ chênh lệch support nền

giữa hai lớp (17,7% và 82,3%), không phải do thiếu luật thật sự. Nhóm luật lift cao nhất toàn cục (38–39) phản ánh hai thuộc tính cùng thiếu dữ liệu (61 giao dịch thiếu Thời tiết, 51 giao dịch thiếu Ánh sáng), không phải insight nghiệp vụ.