

Báo cáo Bài 3 — Luật kết hợp (Association Rules)

Hai bộ dữ liệu: US Accidents và Airbnb — bản rút gọn

Phần A — US Accidents

1. Chuẩn bị dữ liệu giao dịch

Đơn vị giao dịch = 1 vụ tai nạn; item = thuộc tính nhị phân (us_accidents_association_transactions.csv, 80.000 giao dịch × 32 item). 32 item gồm: (a) 9 cờ hạ tầng có sẵn (Crossing, Junction, Traffic_Signal, Railway, Station, Stop, Amenity, Give_Way, No_Exit); (b) 23 item rời rạc hóa từ thuộc tính số/hạng mục — khung giờ (4 mức), loại ngày (thường/cuối tuần), nhóm nhiệt độ, nhóm thời tiết (gộp theo từ khóa), ánh sáng (ngày/đêm), mức độ nghiêm trọng (gộp 1,2→Nhẹ; 3,4→Nặng). Nhóm _Unknown được giữ khi thiếu dữ liệu.

Lý do bổ sung nhóm (b): nếu chỉ dùng 9 cờ hạ tầng, hơn 92% giao dịch chỉ có 0–1 item, không đủ sinh luật có nghĩa. Sau khi bổ sung: trung bình 6,37 item/giao dịch, 100% giao dịch ≥ 2 item. Riêng nhóm Thời tiết (61 giao dịch) và Ánh sáng (51 giao dịch) không có item nào bật — thiếu dữ liệu cục bộ, cần lưu ý khi diễn giải.

2. Thuật toán và ngưỡng

Apriori: dựa trên tính chất downward closure (mọi tập con của tập phổ biến cũng phổ biến) → loại sớm ứng viên chứa tập con không phổ biến; duyệt theo từng mức, dễ bùng nổ ứng viên khi min_support thấp. **FP-Growth:** không sinh ứng viên tường minh, nén dữ liệu vào cây FP-tree dùng chung tiền tố, khai thác đệ quy trên cây điều kiện con. Cả hai là thuật toán chính xác — ở min_support 1% cả hai trả về đúng cùng 1.504 tập phổ biến (đã kiểm chứng bằng so sánh tập hợp).

Thuật toán	min_support	Số tập phổ biến	Thời gian (s)
Apriori	1%	1.504	1,773
Apriori	3%	572	0,109
FP-Growth	1%	1.504	0,379
FP-Growth	3%	572	0,328

Tốc độ không nhất quán: FP-Growth nhanh hơn ở 1% (0,38s so với 1,77s) nhưng Apriori nhanh hơn ở 3% (0,11s so với 0,33s) → không thuật toán nào luôn nhanh hơn; FP-Growth có lợi thế khi số tập phổ biến lớn (ngưỡng support thấp), Apriori lợi thế khi ngưỡng cao (ít tập, chi phí xây FP-tree không còn đáng giá).

Ngưỡng chọn: min_support = 1%, min_confidence = 20%. Confidence thấp có chủ đích vì MucDo_Nang chỉ chiếm 17,7% nền — nếu để confidence $\geq 50\%$, phần lớn luật liên quan mục tiêu chính sẽ bị loại ngay từ đầu.

3. Lọc luật

Sinh luật ban đầu: 9.577 luật. Lọc lift > 1,2 (loại luật tầm thường do item nền tần suất cao như LoaiNgay_NgayThuong 83,5%, MucDo_Nhe 82,3%) → còn 4.244. Lọc luật dư thừa (antecedent A dư thừa nếu tồn

tại $B \subset A$ cùng về phải với $\text{confidence}(B) \geq \text{confidence}(A)$ → còn 2.323. Lọc luật chứa item _Unknown (lift cao nhất toàn tập 38–39 chỉ do 2 thuộc tính cùng thiếu dữ liệu, không phải quan hệ nghiệp vụ) → còn **2.178 luật nghiệp vụ**.

4. Luật nổi bật — hướng tới MucDo_Nang (29 luật)

Điều kiện (A)	Supp.	Conf.	Lift
Junction, NhietDo_Vua	0,0111	0,2667	1,509
NhietDo_Vua, AnhSang_Day, CuoiTuan	0,0122	0,2588	1,464
NhietDo_Vua, CuoiTuan	0,0172	0,2454	1,388
AnhSang_Day, Junction	0,0149	0,2432	1,375
Junction	0,0219	0,2392	1,353

Luật mạnh nhất: {Junction, NhietDo_Vua} → MucDo_Nang, lift 1,51 (tai nạn nặng cao hơn ~51% so với ngẫu nhiên). Phần lớn 29 luật có lift 1,2–1,4 — tương quan tồn tại nhưng không mạnh. **Đối chứng MucDo_Nhe**: 0 luật đạt lift >1,2 sau lọc Unknown — vì MucDo_Nhe chiếm 82,3% nền nên cần confidence >98,8% mới đạt lift 1,2 (gần như bất khả thi), trong khi MucDo_Nang chỉ cần >21,2%. Đây là lý do kỹ thuật cốt lõi khiến hướng khai phá X → MucDo_Nang giàu phát hiện hơn hẳn.

Tổng kết Phần A: Apriori/FP-Growth cho cùng kết quả, tốc độ phụ thuộc ngưỡng (không thuật toán nào luôn thắng). Quá trình lọc: 9.577 → 4.244 (lift) → 2.323 (dư thừa) → 2.178 (loại Unknown). 29 luật liên quan MucDo_Nang, mạnh nhất Junction + NhietDo_Vua (lift 1,51); 0 luật MucDo_Nhe cùng ngưỡng — do chênh lệch support nền (17,7% và 82,3%), không phải thiếu luật thật.

Phần B — Airbnb

1. Chuẩn bị dữ liệu giao dịch

Đơn vị giao dịch = 1 listing; item = 1 tiện nghi nhị phân trong amenities (airbnb_association.csv, 30.218 giao dịch $\times$ 182 item, TB 27,8 item/giao dịch, đã nhị phân hóa sẵn từ Bài 1, không cần rời rạc hóa thêm). Khảo sát cho thấy Wifi (93,57%), Smoke alarm (92,93%), Kitchen (86,30%) gần như phổ biến tuyệt đối $\rightarrow$ loại 3 item này (ngưỡng $>0,85$) trước khi khai phá, còn 179 item.

2. Thuật toán và ngưỡng

Giả định thuật toán giống Phần A. Vì dữ liệu dày đặc hơn nhiều (182 item, TB 27,8/giao dịch so với 32 item, TB 6,37 ở US Accidents), nhóm thử ngưỡng cao hơn hẳn:

min_support	0,20	0,15	0,10	0,08
Số tập phổ biến	24.941	126.142	1.219.391	4.195.080
Th.gian FP-Growth (s)	3,33	8,69	40,75	111,66

Số tập phổ biến tăng theo cấp số nhân khi hạ ngưỡng (0,10 $\rightarrow$ 0,08 tăng $\sim 3,4$ lần). So sánh tốc độ: tại 0,20 Apriori nhanh hơn (3,04s so với 3,98s); tại 0,15 FP-Growth nhanh hơn $\sim 2,1$ lần (12,9s so với 27,1s) — củng cố nhận định ở Phần A rằng FP-Growth chỉ có lợi thế rõ khi số itemsets đủ lớn.

Ngưỡng chọn: min_support = 0,20, min_confidence = 0,60. Ở 0,15 dù itemsets phong phú hơn, bước sinh luật bùng nổ tới 5.878.572 luật (confidence $\geq 0,85$ vẫn còn 1.371.037) — không khả thi để lọc. Ngưỡng 0,20 là điểm cân bằng khả thi giữa tính toán và độ đa dạng luật.

3. Lọc luật

Sinh luật: 711.995. Lọc lift $>1,2 \rightarrow$ còn 694.073 (giảm ít vì phần lớn cặp item vẫn vượt ngưỡng lift). Do quy mô lớn, lấy top 200 theo lift trước khi loại luật dư thừa (cùng tiêu chí Phần A) — toàn bộ 200 luật hàng đầu đều giữ nguyên, không phát sinh luật dư thừa trong tập này.

4. Luật nổi bật

Top 10 luật đều có lift 2,70–2,73, xoay quanh cụm "nhà bếp đầy đủ" (Refrigerator, Stove, Oven, Dishes and silverware, Cooking basics, Hot water):

Antecedent $\rightarrow$ Consequent	Supp.	Conf.	Lift
{Dishes & Silverware, Essentials, Oven} $\rightarrow$ {Cooking basics, Hot water, Refrigerator, Stove}	0,2017	0,7230	2,734
{Refrigerator, Stove} $\rightarrow$ {Dishes & Silverware, Heating, Oven}	0,2038	0,6661	2,712
{Cooking basics, Wine glasses} $\rightarrow$ {Dishes & Silverware, Freezer, Hot water}	0,2014	0,6708	2,707

Độc luật đầu: 20,17% listing có đồng thời cả 7 tiện nghi; trong số có 3 tiện nghi về trái, 72,3% cũng có đủ 4 tiện nghi về phải — khả năng đồng xuất hiện cao gấp 2,73 lần ngẫu nhiên. Đáng chú ý: luật 3 cho thấy Wine glasses (không thuộc nhóm bếp cơ bản) vẫn gắn chặt với cụm bếp đầy đủ — gợi ý phân khúc listing đầu tư đồng bộ cả tiện nghi nấu ăn lẫn tiện nghi cao cấp.

Tổng kết Phần B: FP-Growth không luôn nhanh hơn Apriori, lợi thế phụ thuộc số itemsets — cùng kết luận với Phần A. Mật độ item cao của Airbnb (182 item, TB 27,8/giao dịch so với 32 item, TB 6,37 ở US Accidents) buộc chọn ngưỡng cao hơn hẳn (0,20 so với 0,01) để việc sinh/lọc luật khả thi — minh chứng thực nghiệm cho việc chọn ngưỡng phải phù hợp mật độ dữ liệu.