

Báo cáo Bài 3 — Luật kết hợp (Association Rules)

1. Chuẩn bị dữ liệu giao dịch


Đơn vị giao dịch: mỗi dòng là một vụ tai nạn giao thông, mỗi cột là một item nhị phân (True/False). Dữ liệu đầu vào gồm 80.000 giao dịch × 32 item, kế thừa từ bước chuẩn bị dữ liệu trước đó (us_accidents_association_transactions.csv).

32 item được ghép từ 2 nhóm:

- (a) 9 cờ hạ tầng có sẵn dạng nhị phân: Crossing, Junction, Traffic_Signal, Railway, Station, Stop, Amenity, Give_Way, No_Exit.
- (b) 23 item được rời rạc hóa / one-hot từ thuộc tính số và hạng mục liên tục — xem bảng dưới.

Thuộc tính gốc	Cách rời rạc hóa	Item kết quả
Hour_of_Day (0–23)	4 khung giờ + Unknown nếu thiếu: Sáng (5–10h), Trưa/Chiều (11–16h), Tối (17–20h), Đêm (21–4h)	GioTrongNgay_*
Is_Weekend (bool)	Giữ nguyên, đổi nhãn	LoaiNgay_NgayThuong / CuoiTuan
Temperature_Bin	Nhóm nhiệt độ đã rời rạc hóa từ trước	NhietDo_* (gồm cả Unknown)
Weather_Condition (text)	Gộp nhóm theo từ khóa thời tiết	ThoiTiet_* (gồm cả Unknown)
Sunrise_Sunset	Giữ nguyên, đổi nhãn	AnhSang_Day / Night
Severity (1–4)	Gộp nhị phân: 1,2→Nhẹ; 3,4→Nặng	MucDo_Nhe / MucDo_Nang

Lý do bổ sung nhóm rời rạc hóa: nếu chỉ dùng cờ hạ tầng, hơn 92% giao dịch chỉ có 0–1 item, không đủ để sinh luật hai vế có ý nghĩa. Sau khi bổ sung, mỗi giao dịch có tối thiểu 5 item (trung bình 6,37), 100% giao dịch có ≥ 2 item.



Hình 1. Top 15 item có support cao nhất và phân phối số item/giao dịch

Kiểm tra chất lượng dữ liệu (one-hot theo từng nhóm): các nhóm Khung giờ, Loại ngày, Nhiệt độ, Mức độ nghiêm trọng đều có đúng 1 item bật/giao dịch ở toàn bộ 80.000 dòng. Riêng nhóm Thời tiết có 61 giao dịch và

nhóm Ánh sáng có 51 giao dịch có dữ liệu thiếu ở nguồn gốc, được biểu diễn bằng các item Unknown. Các giao dịch này được lưu ý khi diễn giải kết quả và các luật chứa Unknown được loại khỏi nhóm luật nghiệp vụ.

Biểu đồ bên trái cho thấy một số item nền có support rất cao, như `LoaiNgay_NgayThuong`, `MucDo_Nhe` và `AnhSang_Day`. Điều này cho thấy sự đồng xuất hiện giữa các item phổ biến chưa chắc đã mang ý nghĩa thú vị, vì vậy cần sử dụng lift để lọc các luật có mức liên hệ thấp ở Mục 3. Biểu đồ bên phải cho thấy phần lớn giao dịch có 6–7 item, phù hợp với giá trị trung bình 6,37 item/giao dịch.

2. Thuật toán và ngưỡng

2.1. Giả định và cơ chế của từng thuật toán


- **Apriori**: dựa trên tính chất Apriori (downward closure) — mọi tập con của một tập phổ biến cũng phải phổ biến, nên có thể loại sớm các ứng viên chứa tập con không phổ biến. Duyệt theo từng mức: sinh ứng viên kích thước k từ tập phổ biến $k-1$, quét lại dữ liệu để đếm support. Có thể bùng nổ ứng viên khi `min_support` thấp.
- **FP-Growth**: không sinh ứng viên tường minh. Quét dữ liệu 2 lần để nén giao dịch vào cây FP-tree dùng chung tiền tố, sau đó khai thác đệ quy trên các cây điều kiện con.

Cả hai đều là thuật toán chính xác (không xấp xỉ): nhóm đã kiểm chứng ở `min_support = 1%`, hai thuật toán trả về đúng cùng một tập 1.504 tập phổ biến (so sánh tập hợp, không chỉ số lượng) — khác biệt duy nhất là cách tìm và tốc độ, không phải chất lượng kết quả.

2.2. So sánh tốc độ và ngưỡng


Thuật toán	min_support	Số tập phổ biến	Thời gian (giây)
Apriori	0,3%	3659	3,460
Apriori	1%	1504	0,645
Apriori	3%	572	0,150
FP-Growth	0,3%	3659	0,404
FP-Growth	1%	1504	0,353
FP-Growth	3%	572	0,330

Nhóm thử nghiệm ở 3 ngưỡng (0,3%, 1%, 3%) thay vì chỉ 2 ngưỡng, để có bằng chứng thực nghiệm rõ hơn cho việc hạ `min_support` làm số kết quả tăng nhanh.



Hình 2. Số tập phổ biến theo ngưỡng min_support — tăng từ 572 lên 3.659 khi hạ ngưỡng từ 3% xuống 0,3%

Khi giảm min_support từ 3% xuống 1% rồi tiếp tục xuống 0,3%, số tập phổ biến tăng từ 572 lên 1.504 rồi 3.659. Kết quả cho thấy số tập phổ biến tăng nhanh khi giảm ngưỡng support — đúng như cảnh báo của đề bài (với chỉ 3 điểm đo, nhóm không khẳng định đây là quan hệ hàm mũ chặt chẽ, chỉ ghi nhận xu hướng tăng nhanh). Nếu tiếp tục hạ ngưỡng, số luật (khác với số tập phổ biến) có thể còn tăng nhanh hơn nữa vì mỗi tập phổ biến k-item có thể sinh ra nhiều luật con.



Hình 3. Thời gian chạy Apriori so với FP-Growth ở 3 ngưỡng — không thuật toán nào luôn thắng

Về tốc độ giữa hai thuật toán, kết quả không nhất quán ở cả 3 ngưỡng: FP-Growth nhanh hơn rõ rệt ở ngưỡng thấp (0,3%: 0,404s so với 3,460s của Apriori — khi số ứng viên Apriori phải sinh là lớn nhất), nhưng Apriori lại nhanh hơn ở ngưỡng cao (3%: 0,150s so với 0,330s — khi số ứng viên ít, chi phí xây FP-tree không còn mang lại lợi thế). Vì vậy nhóm không khẳng định một thuật toán luôn nhanh hơn thuật toán còn lại.

Ngưỡng cuối được chọn: min_support = 1%, min_confidence = 20%. Lý do không hạ tiếp xuống 0,3%: dù phát hiện được nhiều tập phổ biến hơn, phần lớn tổ hợp bổ sung có support rất thấp, khó diễn giải và dễ nhiễu, trong khi số luật cần đọc/kiểm chứng thủ công sẽ tăng vượt khả năng phân tích chi tiết trong phạm vi bài tập. Ngưỡng 1% được xem là điểm cân bằng giữa khả năng phát hiện luật và số lượng kết quả có thể diễn giải. Confidence được chọn thấp (20%) có chủ đích vì MucDo_Nang (mục tiêu khai phá chính) chỉ chiếm 17,7% nền — nếu để confidence ≥ 50% như một lựa chọn thông thường, phần lớn luật liên quan tới MucDo_Nang sẽ bị loại ngay từ bước sinh luật.

3. Lọc luật

Sinh luật ở min_support 1%, min_confidence 20% cho ra 9.577 luật. Áp dụng các bước lọc sau:

- **Lọc lift > 1,2:** loại luật tầm thường (gần như luôn đúng chỉ vì item nền có tần suất cao như LoaiNgay_NgayThuong 83,5%, MucDo_Nhe 82,3%) — còn 4.244 luật.
- **Lọc luật dư thừa:** loại luật có antecedent dài hơn nhưng confidence không cao hơn một luật "cha" đơn giản hơn cùng consequent — còn 2.323 luật. Tiêu chí cụ thể:

Một luật $(A \rightarrow C)$ được xem là dư thừa nếu tồn tại một luật khác $(B \rightarrow C)$ sao cho:

- $B \subset A$ (B là tập con thực sự của A , cùng về phải C); và
- $\text{confidence}(B \rightarrow C) \geq \text{confidence}(A \rightarrow C)$.

Nói cách khác: nếu đã có một điều kiện đơn giản hơn (B) cho confidence bằng hoặc cao hơn, thì thêm điều kiện vào để có A không giúp luật mạnh hơn — luật dài $A \rightarrow C$ bị coi là dư thừa và bị loại, chỉ giữ lại luật "cha" $B \rightarrow C$.

- **Lọc luật chứa item _Unknown:** nhóm luật có lift cao nhất toàn bộ tập (38–39) đều xoay quanh các cặp _Unknown (ThoiTiet_Unknown, NhietDo_Unknown) đồng xuất hiện — đây là hệ quả của việc hai thuộc tính cùng bị thiếu dữ liệu ở một số vụ tai nạn, không phải quan hệ nghiệp vụ thật. Các luật này được giữ lại riêng để phát hiện vấn đề chất lượng dữ liệu, nhưng loại khỏi tập dùng để diễn giải — còn 2.178 luật "nghiệp vụ".

4. Luật nổi bật

4.1. Luật liên quan MucDo_Nang (tai nạn nặng)

Trong 2.178 luật nghiệp vụ, có 29 luật có về phải (consequent) là MucDo_Nang.

Điều kiện (A)	Support	Confidence	Lift
Junction, NhietDo_Vua	0,0111	0,2667	1,509
NhietDo_Vua, AnhSang_Day, LoaiNgay_CuoiTuan	0,0122	0,2588	1,464
LoaiNgay_CuoiTuan, ThoiTiet_Nhieu_May	0,0129	0,2545	1,439
GioTrongNgay_Sang, NhietDo_Vua,	0,0133	0,2537	1,435

ThoiTiet_Nhieu_May			
NhietDo_Vua, LoaiNgay_CuoiTuan	0,0172	0,2454	1,388
AnhSang_Day, Junction	0,0149	0,2432	1,375
Junction	0,0219	0,2392	1,353

7 luật tiêu biểu nhất trong tổng số 29 luật hướng tới MucDo_Nang (sắp theo lift giảm dần). Toàn bộ 29 luật được hiển thị đầy đủ trong notebook, mục 6.1 (không rút gọn bằng `.head()`), để đối chiếu khi cần.

Đọc luật hàng đầu: {Junction, NhietDo_Vua} → MucDo_Nang, support 1,1% (1,1% tổng số vụ tai nạn có đồng thời cả 3 điều kiện), confidence 26,7% (trong các vụ có Junction và nhiệt độ vừa, 26,7% là mức nặng — cao hơn tỷ lệ nền 17,68%), lift 1,509 (xác suất xuất hiện MucDo_Nang khi có hai điều kiện này cao hơn khoảng 51% so với mức kỳ vọng nếu điều kiện và mức độ nghiêm trọng độc lập với nhau). Đây là luật có lift cao nhất trong 29 luật hướng tới MucDo_Nang sau các bước lọc — không nhất thiết là luật có support hoặc confidence cao nhất; phần lớn các luật còn lại có lift 1,2–1,4 — tương quan tồn tại nhưng không mạnh, khớp với nhận xét trước đó rằng Severity khó dự đoán chính xác chỉ từ vài đặc trưng đơn lẻ.

4.2. Đối chứng: luật liên quan MucDo_Nhe — 0 luật đạt ngưỡng

Sau khi loại Unknown, không có luật nào dẫn tới MucDo_Nhe đạt lift > 1,2. Điều này chủ yếu được giải thích bởi support nền rất cao của MucDo_Nhe (82,3%): với ngưỡng lift 1,2, confidence của một luật hướng tới MucDo_Nhe cần vượt khoảng $1,2 \times 0,823 \approx 98,8\%$ mới đạt — một mức rất khó gặp trong dữ liệu thực tế. Ngược lại MucDo_Nang chỉ cần confidence > 21,2% để lift vượt 1,2, nên dư địa phát hiện luật rộng hơn nhiều. Đây là lý do kỹ thuật chính giải thích vì sao hướng khai phá $X \rightarrow \text{MucDo_Nang}$ giàu phát hiện hơn hẳn.

5. Tổng kết kỹ thuật

- **So sánh thuật toán:** Apriori và FP-Growth cho cùng kết quả (1.504 tập phổ biến giống hệt nhau tại min_support 1%, đã kiểm chứng bằng so sánh tập hợp). Thử nghiệm ở 3 ngưỡng (0,3%, 1%, 3%) cho thấy tốc độ không nhất quán — FP-Growth có lợi thế rõ khi ngưỡng thấp, Apriori nhanh hơn khi ngưỡng cao — nên không kết luận một thuật toán luôn nhanh hơn. Số tập phổ biến tăng dần khi hạ ngưỡng (572 → 1.504 → 3.659), minh chứng thực nghiệm cho việc hạ ngưỡng làm kết quả tăng nhanh.
- **Ngưỡng và quá trình lọc:** min_support 1%, min_confidence 20%, lọc lift > 1,2 — giảm từ 9.577 luật ban đầu xuống 4.244 (lọc lift), 2.323 (lọc dư thừa theo tiêu chí $B \subset A$ ở Mục 3), còn 2.178 luật nghiệp vụ sau khi loại Unknown.
- **Phát hiện chính:** trong 2.178 luật nghiệp vụ, có 29 luật liên quan MucDo_Nang, luật có lift cao nhất là Junction + NhietDo_Vua (lift 1,51); 0 luật liên quan MucDo_Nhe đạt cùng ngưỡng — chênh lệch bắt nguồn chủ yếu từ chênh lệch support nền giữa hai lớp (17,7% và 82,3%), không phải do thiếu luật thật sự. Nhóm luật lift cao nhất toàn cục (38–39) phản ánh hai thuộc tính cùng thiếu dữ liệu (61 giao dịch thiếu Thời tiết, 51 giao dịch thiếu Ánh sáng), không phải insight nghiệp vụ.